

2万本のPipelineから 「共通中間層」を発見する

汎用化候補を「よく使われる単一テーブル」ではなく、**複数Pipelineで繰り返し連結・JOINされるテーブル群**として捉える。

CORE IDEA

コードは移行対象ではなく、
過去のデータ需要の行動ログである。

誰が、どのテーブルを組み合わせ、どんな中間データを何度作ってきたかを解析する。

ANALYSIS ASSETS

20K

ODM XML Pipeline

N

Connected depth

Databricks

XML解析

Data Usage Graph

Connected Table Set

Fingerprint

「よく使われるテーブル」だけでは、何を汎用化すべきか分からない

単一テーブル中心の見方


1,500

CUSTOMER が1,500 Pipelineで利用

共通性は分かる。しかし「どの状態まで加工して共通化すべきか」は分からない。

VS

今回の見方




同じテーブル群が複数Pipelineで繰り返し連結されているかを見る。

共通の中間状態そのものを、汎用データマート候補として捉える。

Pipelineごとに重複している中間層を見つける



「第N連結」で、テーブル群の広がり方を見る



第1連結

2

tables

A + B

1本のJOIN Edgeで接続

第2連結

3

tables

A + B + C

2本のJOIN Edgeで接続

第3連結

4

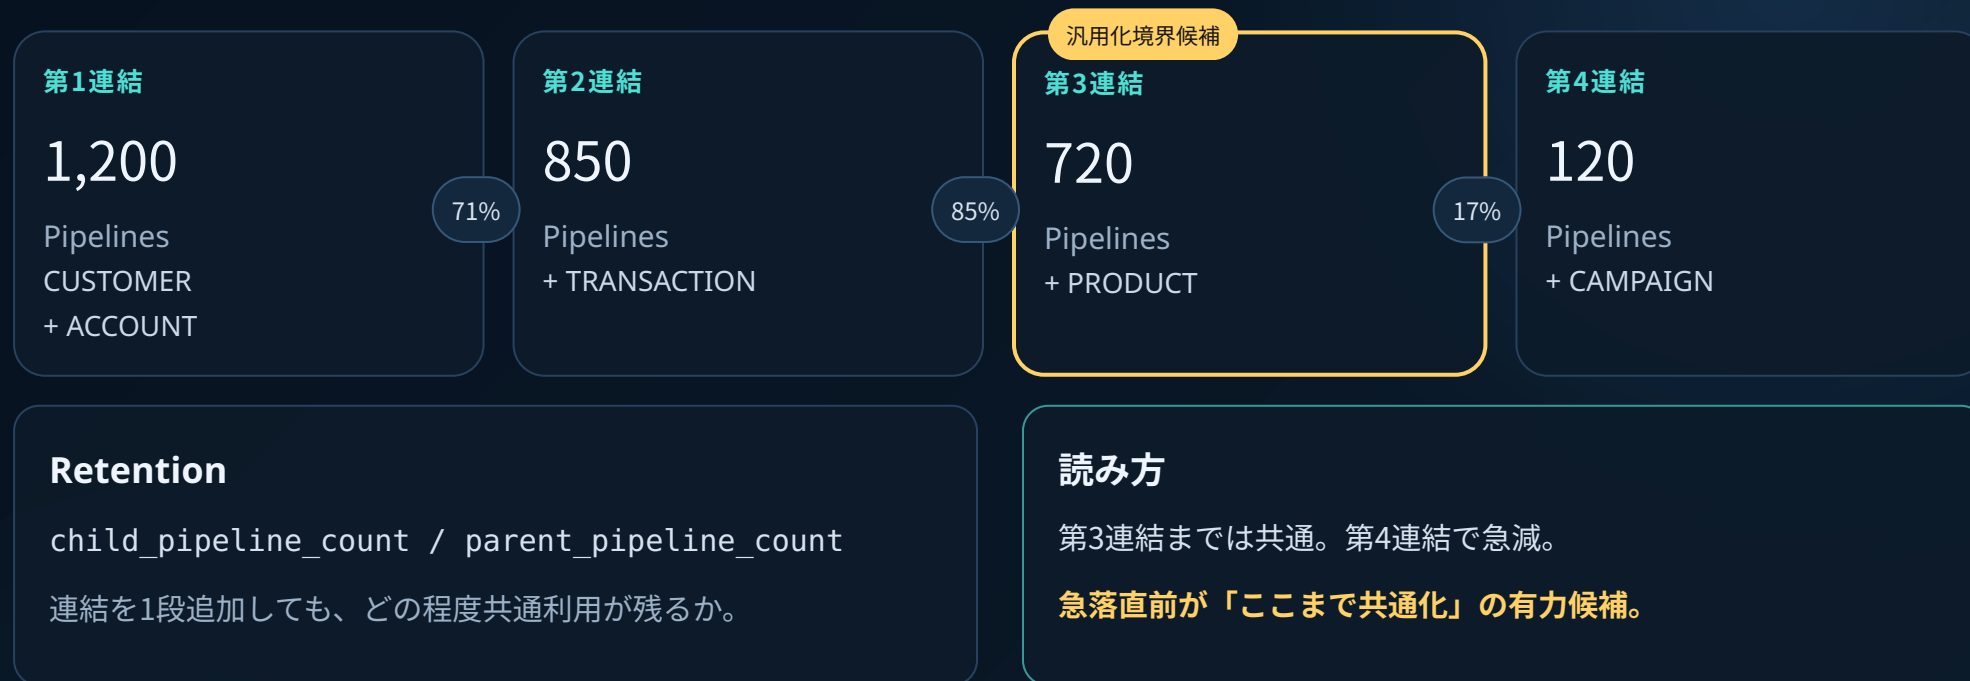
tables

A + B + C + D

3本のJOIN Edgeで接続

一直線のPATHだけでなく、同一Pipeline内でJOINによって接続された **Connected Table Set** を対象にする。

連結を増やしたときの維持率で、汎用化境界を探す



候補は「頻度」だけでなく、複数の証拠で見る

①

Pipeline数

同じTable Setが何本で使われるか

②

部門数

一部門固有か、部門横断か

③

Output多様性

複数用途の前段で再利用されるか

④

継続性

一過性ではなく恒常需要か

⑤

連結深度

第何連結まで共通性が残るか

⑥

Retention

次の連結でどれだけ減衰するか

⑦

Fingerprint

JOIN・集計・粒度も同じか

⑧


下流利用

生成後さらに再利用されるか

Connected Table SetとFingerprintは、別の問いに答える

CONNECTED TABLE SET

どのテーブル群が
セットで使われているか？



共通するデータ構造を発見

PIPELINE FINGERPRINT

そのテーブル群を
どう加工しているか？

JOIN	customer_id
Aggregation	SUM(balance)
Group By	customer_id, year_month
Hash	8AF3897C...

共通する加工ロジックを発見

同じテーブル群 + 同じ加工ロジック
= より強い汎用化候補

Databricks上では、段階的に絞り込む

1 XML Parse

2万Pipelineを構造化

2 JOIN Edge

直接JOIN関係を復元

3 Connected

Set

第1～第N連結を生成

4 Stats

Pipeline・部門・
Output数

5 Retention

親子Setの減衰を見る

6 Fingerprint

有力候補のみ詳細比較

分析テーブル

役割

pipeline_join_edge

Pipeline内の直接JOIN

pipeline_connected_table_set

第N連結のTable Set

connected_table_set_stats

Pipeline数・部門数・Output数


connected_table_set_parent_child

第N→第N+1連結とRetention

connected_table_set_candidate

共通中間層の境界候補

最終的に見たいのは、 「どこまで共通化するか」



個別Pipeline内で毎回作るより、
共通データ資産として一度整備する価値が高い。

コード解析は「候補を発見する証拠」であり、 正解データ定義そのものではない

コードから分かること

- ・ 頻出するTable Set
- ・ 部門横断利用
- ・ JOIN構造
- ・ 共通ロジック
- ・ 継続需要

最後に人が確認すること

- ・ JOIN Key / Type
- ・ Filter条件
- ・ 基準日
- ・ 集計粒度
- ・ 業務定義の統一

コード分析



Connected Set



境界候補



Fingerprint



正式な汎用マート

頻出している定義が、必ずしも業務的に正しいとは限らない。候補抽出後にデータオーナー／業務部門で標準化する。

SUMMARY

この分析の要点

Graph

どこで・どれだけ
使われるかを見る

Set

どのテーブル群が
セットで使われるかを見る

Depth

どこまで共通化
すべきかを見る

Fingerprint

どう加工するか
を比較する

Cluster

似たPipeline
を束ねる

Mart

再利用可能な共通中間層
へ落とし込む

「よく使われるテーブル」ではなく、
“よく繰り返し作られる中間データ構造”を汎用化する。